



TRABALHO DE CONCLUSÃO DE CURSO · PROPOSTA

# Predição de diabetes por aprendizado de máquina supervisionado

*Uma comparação de modelos com ênfase em desempenho preditivo e interpretabilidade*

Lucas Bacil Karam · Israel Marcos Seixas Zibordi · Vitor Henrique de Lima Melo · Henrique Norio Tanaka Aida Oliveira

# Introdução e problema de pesquisa

O diabetes tipo 2 é uma das doenças crônicas que mais crescem no mundo e atinge centenas de milhões de pessoas, boa parte sem diagnóstico. Detectar cedo quem está em risco evita complicações graves (renais, cardíacas e de visão).

O diagnóstico depende de vários fatores clínicos ao mesmo tempo glicose, IMC, pressão, idade, histórico e cada um, isolado, diz pouco. O aprendizado de máquina supervisionado aprende esses padrões e apoia a decisão clínica.

## QUESTÃO DE PESQUISA

**Qual modelo de aprendizado de máquina supervisionado apresenta o melhor equilíbrio entre desempenho preditivo e interpretabilidade clínica na classificação da presença de diabetes a partir de variáveis clínicas?**

# Justificativa

O impasse central: precisão x interpretabilidade na prática clínica

## Métodos ensemble

*random forest, gradient boosting*

- Costumam prever melhor
- Funcionam como caixas-pretas, o que dificulta validação e confiança do profissional

## Regressão logística

*modelo mais simples*

- Fácil de interpretar e explicar
- Pode prever com menos precisão que os métodos ensemble

### Por que medir esse equilíbrio

Rudin (2019) defende preferir modelos interpretáveis em decisões de alto risco, em vez de explicar modelos opacos depois de prontos. Além disso, os zeros inválidos do dataset (glicose e pressão iguais a zero) são dados ausentes e exigem limpeza cuidadosa antes da modelagem.

# Objetivos

## OBJETIVO GERAL

Desenvolver e comparar, em R, modelos de classificação supervisionada para prever o diabetes tipo 2, avaliando desempenho preditivo e interpretabilidade clínica com métricas estatísticas e validação cruzada k-fold.

## OBJETIVOS ESPECÍFICOS

- 1 Implementar quatro modelos (regressão logística, árvore de decisão, random forest e gradient boosting) sobre o Pima Dataset.
- 2 Comparar o desempenho dos métodos ensemble com o da regressão logística, tendo a AUC-ROC como métrica principal.
- 3 Verificar se optar pelo modelo mais interpretável gera perda clinicamente relevante (diferença de AUC > 0,05).
- 4 Investigar como o tratamento dos valores ausentes afeta o desempenho e a estabilidade dos modelos.

# Como o trabalho será conduzido

01

## Dados

Pima Dataset + limpeza dos zeros inválidos (dados ausentes)

02

## Modelagem

4 modelos em R, complexidade crescente

03

## Validação

validação cruzada k-fold

04

## Comparação

AUC-ROC e interpretabilidade clínica

### Orientação

**Orientador pretendido: Prof. Julio Ardito** · **Orientador alternativo: Prof. Marco Vallim**

Área de afinidade: aprendizado de máquina e ciência de dados aplicados à saúde

*Contribuição esperada: apontar qual modelo entrega o melhor equilíbrio entre acertar e ser explicável no apoio ao diagnóstico.*