

Guia de estudo do TCC: predição de diabetes

28 de setembro de 2026 · Lucas Bacil Karam, Israel Marcos Seixas Zibordi, Vitor Henrique de Lima Melo e Henrique Norio Tanaka Aídar Oliveira

O TCC em 30 segundos: comparamos quatro modelos de machine learning para prever diabetes, dos mais transparentes aos mais complexos. A regressão logística acertou praticamente igual ao melhor modelo (AUC 0,836 contra 0,838; diferença de 0,002, contra uma régua de 0,05 definida antes) e é lida com 9 números, em vez de milhares. O resultado não depende de como tratamos os dados faltantes e se repetiu numa base com 253 mil pessoas. Neste problema, a transparência não custa desempenho.

Este guia explica o projeto do zero, em linguagem simples. Cada parte termina com uma frase pronta para a apresentação e com as perguntas que a banca pode fazer.

Conteúdo

1. Parte 1: a história do projeto e o básico de machine learning
2. Parte 2: os dados
3. Parte 3: os 4 modelos
4. Parte 4: como saber se um modelo é bom
5. Parte 5: como comparar de forma justa
6. Parte 6: os dados faltantes (objetivo 4)
7. Parte 7: resultados e interpretabilidade
8. Parte 8: a replicação no CDC e as limitações
9. Os scripts do repositório
10. As figuras e como ler cada uma
11. Perguntas prováveis da banca

Parte 1: a história do projeto e o básico de machine learning

O trabalho pergunta se vale a pena trocar um modelo transparente por uma caixa-preta para prever diabetes. A resposta curta é: não vale.

O problema do mundo real

O diabetes tipo 2 cresce muito, e muita gente tem sem saber. Quando o diagnóstico chega tarde, já podem existir complicações nos rins, no coração e na visão. Nenhum exame sozinho resolve: glicose, peso, pressão, idade e histórico familiar, isolados, dizem pouco. O que funciona é olhar tudo junto, e isso um computador faz bem.

O que é aprendizado de máquina supervisionado

Pense num estagiário de medicina que estuda 768 fichas de pacientes. Cada ficha tem os exames e, embaixo, a resposta: tem ou não tem diabetes. Depois de ver muitas fichas, ele percebe padrões e consegue dar um palpite para uma ficha nova, sem a resposta.

- **Aprendizado de máquina:** o computador aprende padrões a partir de exemplos, em vez de alguém programar as regras.
- **Supervisionado:** os exemplos vêm com a resposta certa, como uma lista de exercícios com gabarito.
- **Classificação:** a resposta é uma categoria (tem ou não tem), e não um número.

Palavra	O que é	No projeto
Variáveis (preditores)	As informações que o modelo usa	Glicose, IMC, idade
Resposta (alvo)	O que se quer adivinhar	Tem diabetes (sim ou não)
Modelo	O estagiário depois de estudar: recebe as variáveis e devolve um palpite	Os 4 modelos comparados

O modelo não responde só sim ou não. Ele devolve uma **probabilidade**, por exemplo "72% de chance de ter diabetes".

Treino e teste: não vale colar

Se a prova tiver as mesmas fichas que o estagiário estudou, ele tira 10 só por ter decorado. Por isso os dados são separados em **treino** (as fichas que o modelo estuda) e **teste** (fichas que ele nunca viu, usadas só para dar a nota). A nota que vale é sempre a do teste.

O dilema que motiva o TCC

- **Modelos simples** (regressão logística, árvore de decisão): dá para abrir e entender por que o paciente recebeu aquele risco.
- **Modelos complexos** (random forest, gradient boosting): juntam centenas de árvores. Costumam acertar mais, mas são caixas-pretas.

Na saúde isso pesa: o médico não deve confiar num resultado que não entende. A pesquisadora Cynthia Rudin (2019), principal referência do trabalho, defende que em decisões de alto risco devemos preferir modelos interpretáveis. A pergunta natural é se a caixa-preta acerta tanto a mais que compensa perder a transparência.

Pergunta de pesquisa e objetivos

Pergunta: qual modelo de aprendizado de máquina supervisionado apresenta o melhor equilíbrio entre desempenho preditivo e interpretabilidade clínica na classificação de diabetes?

1. Implementar os 4 modelos (regressão logística, árvore, random forest e gradient boosting) na base Pima.
2. Comparar os modelos complexos (ensembles) com a regressão logística, usando a AUC-ROC como métrica principal.
3. Verificar se escolher o modelo interpretável causa perda clinicamente relevante. A régua: perda de AUC maior que 0,05 é relevante.
4. Investigar como tratar os valores faltantes (os zeros impossíveis) e o impacto no desempenho e na estabilidade.

A régua de 0,05 foi definida **antes** de ver os resultados (a priori). Isso evita a suspeita de escolher a régua que convinha.

Frase para a apresentação

Modelos complexos costumam ser mais precisos, mas funcionam como caixas-pretas, o que é um problema na saúde. Nosso trabalho mede se essa precisão extra compensa a perda de transparência. Para isso, comparamos quatro modelos e definimos antes uma régua: perder mais de 0,05 de AUC seria clinicamente relevante.

Perguntas da banca

- **Por que machine learning, e não uma regra como "glicose acima de 126"?** Porque o diagnóstico depende de vários fatores ao mesmo tempo. E um dos modelos testados, a árvore, é justamente uma regra simples; o trabalho mostra quanto ela perde.
- **De onde veio o 0,05?** É uma régua do grupo, definida antes da análise. A diferença real (0,002) ficou 25 vezes menor, então uma régua mais rigorosa levaria à mesma conclusão.

Parte 2: os dados

O projeto usa duas bases: a Pima (principal, 768 pacientes com exames) e a CDC (confirmação, 253.680 pessoas com questionário).

A base Pima

- Base clássica, organizada pelo instituto de diabetes dos EUA (NIDDK) e publicada por Smith et al. (1988).
- **768 mulheres** do povo Pima, do Arizona, com 21 anos ou mais. Esse povo tem uma das maiores taxas de diabetes do mundo.
- A base foi retirada do repositório UCI e do pacote `mlbench`. Por isso há uma cópia no projeto (`data/pima_bruto.csv`): o trabalho continua reproduzível mesmo que ela suma da internet.

Variável	O que é
Gestações	Quantas vezes a paciente ficou grávida
Glicose	Açúcar no sangue 2 horas depois de beber uma solução com glicose
Pressão diastólica	A pressão mínima (o segundo número do "12 por 8")
Dobra cutânea do tríceps	Espessura da pele e gordura atrás do braço; estima a gordura corporal
Insulina	Nível de insulina no sangue 2 horas depois do mesmo teste
IMC	Peso dividido pela altura ao quadrado; acima de 30 é obesidade
Histórico familiar (DPF)	Pontuação que resume quantos parentes têm diabetes e com que idade tiveram
Idade	Em anos

A resposta é tem diabetes (pos) ou não tem (neg): **500 sem e 268 com, ou 34,9%**. As classes são desbalanceadas. Um modelo que chuta "não tem" para todo mundo acerta 65% sem aprender nada, por isso a acurácia não é a métrica principal.

O grande problema: os zeros impossíveis

Variável	Pacientes com valor 0	%
Insulina	374	48,7%
Dobra cutânea	227	29,6%
Pressão	35	4,6%
IMC	11	1,4%
Glicose	5	0,7%

Ninguém vivo tem glicose, pressão ou IMC zero. O exame não foi feito, e alguém registrou 0 no lugar de vazio: são **dados faltantes disfarçados**. No total, 376 pacientes têm pelo menos um valor faltando e só 392 têm todos os exames. Se o 0 ficar lá, o modelo aprende coisas absurdas. Isso motiva o objetivo 4 (Parte 6).

Gestações não entra nessa lista: zero gestações é um valor real.

As variáveis separam os grupos?

Variável	Sem diabetes (média)	Com diabetes (média)
Glicose	110,6	142,3
IMC	30,9	35,4
Idade	31,2	37,1
Gestações	3,3	4,9
Insulina	130,3	206,8
Histórico familiar	0,4	0,6

Todas as diferenças são significativas pelo teste de Wilcoxon (que funciona mesmo sem curva normal). A glicose é a que mais separa.

Aqui cada variável é olhada sozinha. Na regressão logística, com todas juntas, insulina, pressão e idade deixam de ser significativas. Não é contradição: a insulina anda junto com glicose e IMC, então acrescenta pouco quando o modelo já sabe essas duas.

A segunda base: CDC

	Pima	CDC
Pessoas	768	253.680 (330 vezes mais)
Quem	Mulheres Pima, 21 anos ou mais	População adulta dos EUA
Coleta	Exames de laboratório	Questionário por telefone (pesquisa BRFSS do CDC)
Variáveis	8 clínicas	21 autodeclaradas
Com diabetes	34,9%	13,9% (pré-diabetes ou diabetes)
Faltantes	Muitos	Nenhum

- **Não é validação externa.** As variáveis são outras, então não dá para testar no CDC o modelo da Pima. O que se repete é o experimento, para ver se a conclusão se mantém (replicação).
- **Autodeclarado** quer dizer que a pessoa responde o que acha ou lembra: menos preciso que exame, mas muito mais barato.
- Há 24.206 linhas repetidas, o que é normal: com respostas sim/não e faixas de idade, muita gente tem o mesmo perfil.

Frase para a apresentação

Usamos a base Pima, com 768 pacientes e 8 variáveis clínicas. Encontramos valores impossíveis, como glicose e pressão iguais a zero, que são exames não registrados; quase metade das pacientes não tem a insulina medida. Para testar se a conclusão depende das particularidades dessa base, repetimos o experimento na base CDC, com mais de 253 mil pessoas.

Perguntas da banca

- **A Pima não é pequena e específica demais?** Sim, e isso está nas limitações. Por isso existe o CDC, onde as AUCs saíram quase iguais.
- **Como sabem que o zero é faltante?** É fisiologicamente impossível. Em gestações, zero é válido e não foi alterado.
- **A glicose não é quase o próprio diagnóstico?** Sim, o diagnóstico usa exames de glicose. Mas o objetivo é comparar modelos, e todos recebem as mesmas variáveis. O CDC, que não tem glicose, chega à mesma conclusão.
- **Por que 14% no CDC e 35% na Pima?** A Pima é uma população de altíssimo risco; o CDC representa a população geral.

Parte 3: os 4 modelos

Os 4 modelos fazem a mesma tarefa, devolver a probabilidade de diabetes, mas pensam de jeitos diferentes. Estão em ordem crescente de complexidade, do mais transparente ao mais caixa-preta.

Regressão logística: a tabela de pontos

Funciona como as calculadoras de risco de revista: "glicose alta, mais 3 pontos; obesidade, mais 2 pontos".

1. Cada variável ganha um **peso** (coeficiente): positivo se aumenta o risco, negativo se diminui.
 2. Para cada paciente, o modelo soma peso vezes valor de cada variável, mais um número fixo (intercepto).
 3. Uma curva em forma de S transforma essa soma numa probabilidade entre 0% e 100%.
- **Por que é transparente:** o modelo inteiro são 9 números. Cada peso vira um odds ratio ("30 mg/dL a mais de glicose deixa a chance 3,3 vezes maior"). Dá para calcular o risco à mão.
 - **Limitação:** cada variável soma seu efeito separadamente. Interações complexas ("IMC alto só importa se a glicose também for alta") não são captadas sozinhas.

Árvore de decisão (CART): o fluxograma

Como o jogo "é animal? tem 4 patas? late?": perguntas de sim ou não até chegar a uma resposta. O modelo testa todas as perguntas possíveis, escolhe a que melhor separa doentes de saudáveis e repete dentro de cada lado. No fim de cada caminho fica uma **folha** com o risco.

A árvore final do projeto:

- Glicose menor que 127,5: risco de 19%
- Glicose 127,5 ou mais e IMC menor que 29,95: risco de 32%
- Glicose 127,5 ou mais e IMC 29,95 ou mais: risco de 73%

Overfitting (decorar em vez de aprender): sem limite, a árvore cria perguntas até cada folha ter uma ou duas pacientes e erra muito em pacientes novas. A solução é a **poda pela regra do 1-SE**: entre as árvores com erro estatisticamente empatado com o da melhor, fica a mais simples.

- **Por que é transparente:** o fluxograma acima é o modelo inteiro (5 nós, 2 variáveis).
- **Limitação:** só 3 níveis de risco. Uma paciente com glicose 128 e outra com 190 recebem o mesmo risco.

Random forest: a junta médica com 500 opiniões

1. Cria 500 árvores.
2. Cada árvore estuda uma amostra sorteada das pacientes (com reposição).
3. Em cada pergunta, a árvore só pode escolher entre 2 variáveis sorteadas das 8. Isso obriga as árvores a serem diferentes.
4. Para uma paciente nova, as 500 árvores votam: se 350 dizem "diabetes", o risco é 70%.

Cada árvore sozinha é fraca, mas erra de um jeito diferente; na média, os erros se cancelam. É caixa-preta: são 124.748 nós. Dá para saber quais variáveis importam, mas não em que direção, nem por que uma paciente recebeu aquele risco.

Gradient boosting (GBM): a equipe que corrige os erros da anterior

1. Começa com um palpite básico (a proporção geral de diabéticos).
2. Cria uma árvore pequena (3 perguntas) focada em corrigir os erros do palpite atual.
3. Soma só 1% dessa árvore ao palpite (a taxa de aprendizado, 0,01), para avançar com cuidado.
4. Repete até que mais árvores deixem de ajudar. Esse ponto é escolhido pelo critério OOB; no modelo final foram 227 árvores.

Na random forest as árvores são independentes e votam em paralelo. No boosting elas são em sequência, e cada uma depende da anterior. Também é caixa-preta: 1.589 nós.

Ensemble quer dizer "conjunto": um modelo feito de vários modelos menores. Random forest e GBM são ensembles, e o objetivo 2 compara os dois com a logística.

Resumo

	Logística	Árvore	Random forest	GBM
Analogia	Tabela de pontos	Fluxograma	Junta médica votando	Equipe corrigindo erros
Tamanho	9 números	5 nós	124.748 nós	1.589 nós
Dá para ler?	Sim	Sim	Não	Não
Mostra a direção do efeito?	Sim, com número	Em parte	Não	Não
Capta interações complexas?	Não sozinha	Um pouco	Sim	Sim

Ajustes fixos (hiperparâmetros)

Os "botões" de cada modelo (número de árvores, profundidade, taxa de aprendizado) usam valores fixos, comuns na literatura e documentados. Não houve busca da melhor combinação.

- **Vantagem:** evita resultado otimista. Testar 100 combinações e escolher a melhor nos mesmos dados infla a nota.
- **Desvantagem:** random forest e GBM talvez melhorassem um pouco. Está nas limitações.

Frase para a apresentação

Comparamos quatro modelos em ordem crescente de complexidade. A regressão logística funciona como uma tabela de pontos, com 9 números que podem ser lidos. A árvore de decisão é um fluxograma de perguntas. A random forest junta 500 árvores que votam, e o gradient boosting encadeia árvores que corrigem os erros das anteriores. Esses dois últimos costumam ser mais precisos, mas são caixas-pretas, com milhares de elementos.

Perguntas da banca

- **Por que esses 4 e não redes neurais ou SVM?** Eles cobrem o espectro de interpretabilidade: dois transparentes clássicos e os dois ensembles mais usados em dados de planilha. Em bases pequenas desse tipo, redes neurais raramente superam o boosting.

- **Por que não otimizaram os hiperparâmetros?** Para evitar resultado otimista. A vantagem dos ensembles teria que crescer de 0,002 para mais de 0,05 para mudar a conclusão.
- **O que é overfitting?** O modelo decora o treino, incluindo o ruído, e vai mal em dados novos. A proteção é a poda, a parada automática do GBM e, principalmente, avaliar sempre em dados de teste.

Parte 4: como saber se um modelo é bom

A métrica principal é a AUC-ROC, porque ela não depende de um ponto de corte e não é enganada pelo desbalanceamento. Os exemplos abaixo usam sempre **100 pacientes, 35 com diabetes e 65 sem**.

Da probabilidade ao sim ou não: o limiar

O modelo devolve uma probabilidade. Para decidir, usa-se um ponto de corte (limiar): se o risco for 50% ou mais, "tem diabetes". O limiar 0,5 é o padrão, mas é uma escolha.

Os 4 tipos de acerto e erro (matriz de confusão)

	Modelo diz: tem	Modelo diz: não tem
Tem de verdade	Verdadeiro positivo	Falso negativo: o doente que passou despercebido
Não tem de verdade	Falso positivo: o alarme falso	Verdadeiro negativo

Numa triagem, o falso negativo é o erro mais grave: a pessoa doente vai para casa achando que está bem.

Métricas que dependem do limiar

Regressão logística com limiar 0,5, nas 100 pacientes:

Métrica	Pergunta que responde	No exemplo
Sensibilidade	Dos doentes, quantos o modelo encontrou?	20 de 35: 57%
Especificidade	Dos saudáveis, quantos foram liberados corretamente?	57 de 65: 87%
Precisão	De quem foi acusado, quantos eram doentes?	20 de 28: 71%
Acurácia	Quantos acertos no total?	77 de 100: 77%
F1	Equilíbrio entre precisão e sensibilidade	0,63

Com limiar 0,5, o modelo deixa passar 15 dos 35 doentes. Isso vale para os 4 modelos (sensibilidade entre 53% e 59%).

Por que a acurácia não é a principal: chutar "não tem" para todo mundo dá 65% de acurácia na Pima e 86% no CDC, sem aprender nada. Além disso, todas essas métricas mudam quando o limiar muda.

Curva ROC e AUC

A **curva ROC** testa todos os limiares e marca, para cada um, a sensibilidade (eixo vertical) contra a taxa de alarmes falsos (eixo horizontal). Quanto mais a curva sobe para o canto superior esquerdo, melhor. A diagonal é o chute.

A **AUC** é a área embaixo da curva. A melhor forma de explicar: *sorteie uma paciente com diabetes e uma sem; a AUC é a chance de o modelo dar um risco maior para a que tem diabetes.*

AUC	Significado
0,5	Cara ou coroa
0,7 a 0,8	Aceitável (a árvore, 0,73)
0,8 a 0,9	Bom (logística, RF e GBM, cerca de 0,83)
1,0	Perfeito

A AUC mede se o modelo **ordena** bem as pessoas, e não se os números de probabilidade estão certos. Para isso existe a calibração.

Brier: o erro das probabilidades

Mede o quanto cada probabilidade errou, com o erro ao quadrado. Dar 90% para quem tem diabetes gera erro 0,01; dar 90% para quem não tem gera erro 0,81. Quanto menor a média, melhor. Chutar 35% para todo mundo daria cerca de 0,23. Resultados: logística 0,157, GBM 0,159, RF 0,160, árvore 0,185.

Calibração: quando o modelo diz 30%, é 30% mesmo?

Pense na previsão do tempo: se ela diz "30% de chuva" em 100 dias, deveria chover em uns 30. Na clínica, o médico decide com base no número, então ele precisa ser honesto.

- **Intercepto (ideal 0):** o modelo exagera ou subestima o risco em geral? Os 4 ficaram perto de 0.
- **Inclinação (ideal 1):** menor que 1, o modelo é exagerado; maior que 1, é tímido (fica perto da média).

Modelo	Inclinação	Leitura
Random forest	1,00	Perfeita
Logística	0,93	Muito boa
Árvore	0,76	Exagerada, com só 3 níveis de risco
GBM	1,37	Tímido: probabilidades espremidas perto da média

O GBM tem a melhor AUC e a pior calibração entre os três bons. Não é contradição: ele ordena bem, mas os números estão comprimidos. A causa provável é o critério OOB parar com árvores de menos.

Ponto de triagem: sensibilidade fixada em 80%

Pergunta: se o modelo for obrigado a encontrar pelo menos 80% dos diabéticos, quantos saudáveis ele ainda libera corretamente?

Modelo	Especificidade com sensibilidade de 80%
GBM	73%
Random forest	72%
Logística	69%
Árvore	17%

As diferenças entre logística, RF e GBM não são significativas ($p = 0,34$ e $0,23$). A árvore despenca porque, com 3 níveis de risco, precisa acusar quase todo mundo para chegar a 80%. Esse é um ponto da curva ROC para comparar modelos, e não um limiar pronto para o consultório.

Frase para a apresentação

Usamos a AUC-ROC como métrica principal porque ela não depende de um ponto de corte e não é enganada pelo desbalanceamento das classes. Ela representa a chance de o modelo dar um risco maior a um paciente doente do que a um saudável. Avaliamos também a calibração e um ponto de triagem com sensibilidade de 80%.

Perguntas da banca

- **O que significa AUC de 0,836?** Em 83,6% dos pares (um doente, um saudável), o modelo dá risco maior ao doente.
- **Por que a sensibilidade é tão baixa?** Por causa do limiar 0,5 com classes desbalanceadas. Por isso existe o ponto de triagem.
- **O GBM tem a maior AUC. Por que não ele?** A vantagem é de 0,002 (empate estatístico), ele é pior calibrado e é caixa-preta.
- **Qual a diferença entre AUC e calibração?** A AUC diz se o modelo ordena bem; a calibração diz se os números estão certos.

Parte 5: como comparar de forma justa

Cada modelo foi avaliado 50 vezes, sempre em pacientes que ele não viu, e todos fizeram as mesmas provas. É o coração metodológico do TCC.

O problema de fazer só uma prova

Separar 70% para treino e 30% para teste uma única vez depende de sorte. Se o teste pegar pacientes fáceis, todos parecem ótimos; com só 768 pacientes, outro sorteio poderia até inverter quem ganha.

Validação cruzada 10-fold

1. Divide as 768 pacientes em 10 partes (folds) de cerca de 77.
2. Rodada 1: a parte 1 é a prova e as outras 9 (cerca de 691) são o treino.
3. Rodada 2: a parte 2 é a prova. E assim até a rodada 10.

Cada paciente faz a prova exatamente uma vez, e o modelo é sempre avaliado em quem não estudou.

- **Estratificada:** cada parte tem cerca de 35% de diabéticos, igual à base inteira.
- **Repetida 5 vezes:** embaralha e refaz tudo, para que a divisão específica não influencie.

10 partes vezes 5 repetições = 50 provas por modelo. Daí vem o " $0,836 \pm 0,042$ ": média de 0,836 e variação típica de 0,042 entre as provas (a estabilidade).

A mesma prova para todos (comparação pareada)

Os 4 modelos fizeram as mesmas 50 provas, com as mesmas pacientes e a mesma semente aleatória. Assim, em cada prova, calcula-se uma diferença (por exemplo, AUC do GBM menos AUC da logística). A dificuldade de cada prova afeta os dois igualmente e sai da conta; sobra só a diferença entre os modelos.

Semente fixa (2026): todo sorteio usa a mesma semente, então qualquer pessoa que rodar o código obtém exatamente os mesmos números. Isso é reprodutibilidade.

Não espiar a prova (vazamento de dados)

Vazamento é usar informação da prova antes da prova. Exemplo: calcular a mediana para preencher faltantes usando as 768 pacientes deixa as pacientes da prova ajudarem no treino.

A regra do projeto: **tudo que aprende algo dos dados (a mediana, o modelo de preenchimento) é calculado só com o treino de cada rodada e depois aplicado à prova.** Isso é feito nas 50 rodadas.

Os modelos treinados com as 768 pacientes servem só para mostrar o que aprenderam. Nenhuma nota de desempenho vem deles.

A diferença é real ou foi sorte?

- **Intervalo de confiança de 95% (IC):** faixa onde provavelmente está a diferença verdadeira. Se inclui o zero, não dá para afirmar que um modelo é melhor.
- **p-valor:** se os modelos fossem iguais, qual a chance de ver uma diferença assim só por sorte? Abaixo de 0,05, a diferença dificilmente é sorte.

Por que o teste t precisa ser corrigido: o teste comum supõe que as 50 medições são independentes. Aqui elas não são: entre duas rodadas, o treino tem cerca de 89% das pacientes em comum, e as repetições usam as mesmas 768 pacientes. O teste comum acharia diferenças onde não existem. A correção de Nadeau e Bengio (2003) aumenta a incerteza na medida certa; aqui, o IC fica cerca de 2,5 vezes mais largo. Escolher o teste mais conservador é um ponto forte do trabalho.

Resultado (logística como referência)

Comparação	Diferença de AUC	IC 95%	p	Leitura
GBM menos logística	+0,002	-0,015 a +0,019	0,85	Empate
RF menos logística	-0,007	-0,028 a +0,013	0,46	Empate
Árvore menos logística	-0,105	-0,149 a -0,062	abaixo de 0,001	A árvore é pior

O GBM venceu a logística em 52% das provas: praticamente cara ou coroa.

Não significativo não quer dizer igual. Quer dizer só "não consegui provar que é diferente". A resposta está no IC: no pior cenário, o GBM seria 0,019 melhor, ainda abaixo da régua de 0,05. A frase certa é: *mesmo no cenário mais favorável ao GBM, a vantagem não seria clinicamente relevante.*

No CDC, com 253 mil pessoas, foram 5 partes vezes 2 repetições (10 provas). Cada prova tem cerca de 50 mil pessoas, então a nota quase não varia.

Frase para a apresentação

Avaliamos os modelos com validação cruzada estratificada de 10 partes, repetida 5 vezes: 50 avaliações por modelo, sempre em pacientes que o modelo não viu. Todos os modelos fizeram as mesmas provas, o que permite comparação pareada. Todo pré-processamento foi aprendido só no treino de cada rodada. Para testar as diferenças, usamos o teste t corrigido de Nadeau e Bengio, mais conservador porque as rodadas compartilham pacientes.

Perguntas da banca

- **Por que não uma divisão simples 70/30?** Com 768 pacientes, uma divisão depende muito de sorte. A validação cruzada repetida usa todas as pacientes como teste e dá 50 medições.
- **Por que 10 partes?** É o padrão da literatura: treino grande (90% dos dados) e várias provas.
- **Não achar diferença prova que são iguais?** Não. O que se mostra é que o IC inteiro fica abaixo de 0,05.
- **Os modelos finais com 768 pacientes não estão superestimados?** Eles não medem desempenho; todas as métricas vêm das 50 provas.

Parte 6: os dados faltantes (objetivo 4)

Tratar os zeros como faltantes melhorou pouco a AUC, sem diferença significativa, e a conclusão sobre os modelos foi a mesma nas quatro estratégias testadas.

Primeiro passo

Nas 5 variáveis em que zero é impossível (glicose, pressão, dobra cutânea, insulina e IMC), o 0 vira NA, a marcação de dado ausente no R. Gestações não entra.

As 4 estratégias

Estratégia	O que faz	Problema
Zeros mantidos	Nada: trata o 0 como medida real. É a linha de base	Ensina coisas absurdas ao modelo
Casos completos	Remove quem tem algum buraco	Sobram só 392 de 768, possivelmente um grupo diferente
Mediana	Preenche com o valor do meio (resistente a extremos, ao contrário da média)	Todo mundo com buraco recebe o mesmo número
MICE (principal)	Estima o buraco olhando o resto da ficha	Supõe que a falta pode ser explicada pelas outras variáveis

Como funciona o MICE

Pense num médico diante de uma ficha com a insulina em branco: ele pensa "glicose alta e IMC alto costumam vir com insulina alta". O MICE (imputação múltipla por equações encadeadas) faz isso:

1. Faz um primeiro chute simples em todos os buracos.
2. Cria um pequeno modelo que prevê a insulina a partir das outras variáveis e refaz os buracos da insulina.
3. Faz o mesmo com a dobra cutânea, depois com a pressão, e assim por diante (por isso "encadeadas").
4. Repete o ciclo 10 vezes, e as estimativas ficam mais coerentes entre si.

O **pmm** (predictive mean matching) procura pacientes reais parecidas e copia um valor que foi de fato medido numa delas. Assim o valor preenchido é sempre realista.

O MICE foi escolhido como principal **antes** da análise porque mantém as 768 pacientes, respeita a relação entre as variáveis e é o mais recomendado na literatura (Van Buuren, 2011).

Sem espiar a prova

Em cada uma das 50 rodadas, a mediana e o modelo do MICE são aprendidos só com o treino. As pacientes da prova são preenchidas, mas não ensinam nada ao preenchedor. E a resposta (tem ou não diabetes) **não** entra no preenchimento: na vida real, não se sabe o diagnóstico da paciente nova, e usá-lo seria dar o gabarito.

O que saiu (AUC média)

Modelo	Zeros mantidos	Casos completos*	Mediana	MICE
Logística	0,831	0,845	0,836	0,836
Árvore	0,714	0,765	0,731	0,731
Random forest	0,828	0,849	0,831	0,829
GBM	0,834	0,855	0,838	0,838

*Avaliado em outra amostra (392 pacientes), então não é comparável diretamente.

1. **Tratar os zeros ajuda pouco:** de +0,000 a +0,017, nenhuma diferença significativa.
2. **A árvore é a mais sensível:** ela escolhe cortes como "IMC 29,95 ou mais", e pacientes com IMC 0 bagunçam esses cortes.
3. **Mediana e MICE deram quase igual** nesta base.
4. **A conclusão sobre os modelos não muda** em nenhuma estratégia: é um teste de robustez.

A pegadinha dos casos completos: os números são os maiores, mas é outra prova (392 pacientes, talvez um grupo diferente), é menos estável (cada prova tem só cerca de 39 pacientes; na logística a variação sobe de 0,042 para 0,049) e não serve na prática, porque pacientes novas também chegam sem exames. Por isso essa comparação é só descritiva.

Imputação única e múltipla

Preencher uma vez só faz o modelo tratar o palpite como medida real. Ele fica confiante demais, e os intervalos de confiança saem estreitos demais. A **imputação múltipla** preenche 20 vezes, roda a regressão em cada versão e combina os resultados pelas **regras de Rubin**. Se as versões discordam, o intervalo fica mais largo.

- **Na validação cruzada (medir desempenho):** única ($m = 1$), por custo computacional. Está nas limitações.
- **Nos odds ratios (explicar a logística):** múltipla ($m = 20$).

Por que a resposta entra no preenchimento dos odds ratios

	Validação cruzada	Odds ratios
Objetivo	Prever pacientes novos	Medir a relação entre variáveis e diabetes
Tem prova?	Sim, com o gabarito escondido	Não
A resposta entra no preenchimento?	Não: seria dar o gabarito	Sim: é o recomendado

Sem a resposta, o preenchedor cria valores sem ligação com o diabetes, o que dilui a relação verdadeira e puxa os odds ratios para 1 (Moons et al., 2006). O projeto separou as duas mudanças:

Cenário	OR da glicose	Largura do IC
A: preenche 1 vez, sem a resposta	3,05	referência
B: preenche 20 vezes, sem a resposta	3,16	+5%

Cenário	OR da glicose	Largura do IC
C: preenche 20 vezes, com a resposta (usado)	3,28	+14%

De A para B, o IC fica mais honesto. De B para C, o OR se afasta de 1. Cada mudança responde por cerca de metade do aumento.

Frase para a apresentação

Tratamos os zeros impossíveis como dados ausentes e comparamos quatro estratégias: manter os zeros, remover pacientes incompletas, preencher com a mediana e imputação múltipla (MICE), definida a priori como principal. Todo preenchimento foi aprendido só com os dados de treino. O tratamento melhorou pouco a AUC, sem diferença significativa, e a conclusão sobre os modelos foi a mesma nas quatro estratégias.

Perguntas da banca

- **Por que não apagar quem tem buraco?** Joga fora quase metade da base, pode deixar um grupo diferente e não resolve o uso prático.
- **Casos completos deram a maior AUC. Por que não é a melhor?** É outra amostra, menor e com mais variação; as notas não são comparáveis.
- **Por que $m = 1$ na validação cruzada?** Custo computacional. Mediana e MICE deram a mesma AUC, então 20 preenchimentos dificilmente mudariam a comparação.
- **O MICE supõe algo sobre por que os dados faltam?** Sim: que a falta pode ser explicada pelas outras variáveis observadas (o termo técnico é MAR). Na insulina isso pode não valer, se o exame só foi pedido para certas pacientes. É uma suposição que não dá para verificar; por isso foram testadas quatro estratégias, e a conclusão foi a mesma.

Parte 7: resultados e interpretabilidade

A regressão logística oferece o melhor equilíbrio: acerta praticamente igual ao melhor modelo e é o único que atende aos três critérios práticos de interpretabilidade.

O placar geral (MICE, média das 50 provas)

Modelo	AUC	Brier	Calibração (inclinação)
Gradient boosting	0,838 ± 0,045	0,159	1,37 (tímido)
Regressão logística	0,836 ± 0,042	0,157	0,93 (boa)
Random forest	0,829 ± 0,048	0,160	1,00 (perfeita)
Árvore de decisão	0,731 ± 0,063	0,185	0,76 (exagerada)

Objetivo 2: os ensembles não ganham da logística de forma significativa (GBM +0,002, $p = 0,85$; RF -0,007, $p = 0,46$), nas 4 estratégias de faltantes.

Objetivo 3: a régua de 0,05

A resposta depende de onde o IC cai em relação à régua:

- **IC inteiro abaixo de 0,05:** perda não relevante.
- **IC atravessa 0,05:** inconclusivo.
- **IC inteiro acima de 0,05:** perda relevante.

Troca	Perda de AUC	IC 95%	Resultado
GBM para logística	0,002	-0,015 a 0,019	IC inteiro abaixo de 0,05: não relevante
GBM para árvore	0,107	0,064 a 0,150	IC inteiro acima de 0,05: relevante

Os dois casos caíram nos cenários claros, e isso vale nas 4 estratégias de faltantes.

Lendo a logística: os odds ratios

Chance não é probabilidade. Chance é a probabilidade de acontecer dividida pela de não acontecer: 50% dá chance 1; 75% dá chance 3; 35% dá chance 0,54.

O **odds ratio (OR)** diz quantas vezes a chance é multiplicada quando a variável aumenta. OR igual a 1 é sem efeito; maior que 1 aumenta o risco; menor que 1 diminui. Os ORs são **por +1 desvio-padrão** (um "passo típico" de cada variável), para ficarem comparáveis entre si.

Variável	+1 DP equivale a	OR	IC 95%	Significativo?
Glicose	+30,5 mg/dL	3,28	2,45 a 4,38	Sim
IMC	+6,9 kg/m ²	1,84	1,38 a 2,45	Sim
Gestações	+3,4	1,50	1,21 a 1,87	Sim

Variável	+1 DP equivale a	OR	IC 95%	Significativo?
Histórico familiar	+0,33	1,34	1,10 a 1,63	Sim
Idade	+11,8 anos	1,18	0,94 a 1,48	Não
Dobra cutânea	+10,5 mm	1,10	0,81 a 1,50	Não
Pressão	+12,4 mmHg	0,89	0,72 a 1,09	Não
Insulina	+118,8	0,88	0,63 a 1,24	Não

Como ler: mantendo as outras variáveis iguais, cada 30 mg/dL a mais de glicose multiplica a chance de diabetes por 3,3. Se o IC atravessa o 1 (como na idade), não dá para afirmar efeito depois de considerar as outras variáveis.

Cuidado com "triplica o risco": o OR multiplica a chance, não a probabilidade. Com probabilidade de 35% (chance 0,54), mais 30 mg/dL de glicose leva a chance a 1,77, ou seja, probabilidade de 64%. Prefira dizer "a chance fica 3,3 vezes maior".

Lendo a árvore: 3 regras

- Glicose menor que 127,5: risco de 19% (484 pacientes)
- Glicose 127,5 ou mais e IMC menor que 29,95: risco de 32% (76 pacientes)
- Glicose 127,5 ou mais e IMC 29,95 ou mais: risco de 73% (208 pacientes)

Qualquer pessoa entende em 10 segundos, e a árvore chegou sozinha às mesmas duas variáveis mais fortes da logística. Mas joga informação fora e perde 0,107 de AUC.

Os 4 modelos concordam?

Variável	Logística	Árvore	Random forest	GBM
Glicose	1°	1°	1°	1°
IMC	2°	2°	2°	2°
Idade	5°	4°	3°	3°
Gestações	3°	8°	5°	6°

Glicose e IMC são as mais importantes nos quatro modelos, que usam lógicas completamente diferentes. Isso bate com a medicina: glicose é o marcador do diabetes e obesidade é o principal fator de risco do tipo 2.

A árvore usa só 2 variáveis, mas tem ranking para as 8. É que o pacote `rpart` também conta as "divisões substitutas", variáveis que fariam um corte parecido se a principal faltasse.

A interpretabilidade com números

Modelo	AUC	Perda	Tamanho	Calcula à mão?	Direção do efeito?	Explica cada paciente?
Logística	0,836	0,002	9 coeficientes	Sim	Sim, com IC	Sim
Árvore	0,731	0,107	5 nós	Sim	Em parte	Sim

Modelo	AUC	Perda	Tamanho	Calcula à mão?	Direção do efeito?	Explica cada paciente?
Random forest	0,829	0,009	124.748 nós	Não	Não	Não
GBM	0,838	0	1.589 nós	Não	Não	Não

- **Tamanho:** quantos elementos é preciso ler para entender o modelo inteiro.
- **Calcula à mão:** dá para chegar ao risco sem computador?
- **Direção do efeito:** dá para saber se a variável aumenta ou diminui o risco, e quanto?
- **Explica cada paciente:** dá para dizer por que esta paciente recebeu este risco?

A figura 04_equilibrio.png junta tudo: a logística é o único ponto dentro da faixa de perda não relevante e à esquerda (pequeno). É a resposta da pergunta de pesquisa em uma imagem, e confirma a tese de Rudin (2019).

Frase para a apresentação

A regressão logística teve AUC de 0,836, contra 0,838 do gradient boosting. A diferença de 0,002 não é significativa, e mesmo no pior cenário não passaria de 0,019, abaixo do limite de 0,05. Ela é bem calibrada e é lida com 9 números, contra 1.589 do boosting e mais de 124 mil da random forest. A árvore é a mais simples, mas perde 0,107 de AUC. Por isso a regressão logística oferece o melhor equilíbrio.

Perguntas da banca

- **A insulina não é significativa. Não tem relação com diabetes?** Tem, sozinha. Ela só não acrescenta informação depois da glicose e do IMC, e tem 49% de faltantes.
- **Isso prova que glicose causa diabetes?** Não. São associações num estudo observacional; no caso da glicose, a relação é quase de definição.
- **Por que não usar a árvore, se é a mais simples?** Perde 0,107 de AUC e só dá 3 níveis de risco.
- **Por que não explicar o GBM com SHAP?** Explicações feitas depois são aproximações do modelo. Se um modelo transparente acerta igual, é preferível (argumento de Rudin).
- **Os critérios de interpretabilidade não são subjetivos?** Em parte, e isso está nas limitações. Mas o tamanho é objetivo, e a diferença (9, 1.589, 124.748) é grande demais para qualquer critério razoável mudar a conclusão.

Parte 8: a replicação no CDC e as limitações

Com 330 vezes mais dados, as AUCs ficaram praticamente iguais e a conclusão se manteve: o GBM passa a ganhar de forma significativa, mas por uma diferença clinicamente irrelevante.

O que mudou no CDC

Mudança	Motivo
Validação 5 partes vezes 2 (10 provas)	Com 253 mil pessoas, 10 vezes 5 levaria horas; cada prova tem cerca de 50 mil pessoas
Random forest com o pacote <code>ranger</code>	Mesmo algoritmo, muito mais rápido
Sem estratégias de faltantes	A base não tem dados faltando; o objetivo 4 não se aplica
SMD no lugar do p-valor na descritiva	Com n enorme, qualquer diferença dá p abaixo de 0,001. A SMD mede o tamanho da diferença (acima de 0,1 importa, acima de 0,5 é grande)
AUC-PR como métrica extra	Explicado abaixo
Limiar de 14% além do 0,5	Explicado abaixo

O limiar 0,5 não serve com 14% de doentes: quase ninguém chega a 50% de risco, e a sensibilidade cai para 15% a 19%. Com o limiar na prevalência (14%), sobe para cerca de 77%. O limiar precisa combinar com a população.

AUC-PR: com doentes raros, a AUC-ROC pode parecer boa mesmo com muitos alarmes falsos. A AUC-PR olha só para quem foi acusado. Um chute tira 0,14; o GBM tirou 0,43 e a logística 0,40, cerca de 3 vezes melhor que o chute.

Resultados no CDC

Modelo	AUC-ROC	AUC-PR	Brier	AUC na Pima
Gradient boosting	0,829 ± 0,001	0,430	0,097	0,838
Regressão logística	0,822 ± 0,001	0,405	0,099	0,836
Random forest	0,822 ± 0,001	0,421	0,098	0,829
Árvore	0,730 ± 0,008	0,310	0,106	0,731

Significativo não é o mesmo que importante

No CDC, o GBM ganhou da logística em todas as 10 provas: +0,007, IC de 0,006 a 0,009, p abaixo de 0,001. Isso não derruba a conclusão. Com muitos dados, até diferenças minúsculas viram significativas: o teste diz que a diferença existe, não que ela importa. O IC inteiro está 5 a 8 vezes abaixo da régua de 0,05. É um ganho real, mas clinicamente irrelevante.

Na Pima, 768 pessoas não bastavam para enxergar um efeito tão pequeno; com 253 mil, ele aparece, e é do tamanho que o IC da Pima permitia. As duas bases contam a mesma história. A random forest empatou com a logística ($p = 0,80$), e a árvore voltou a perder de forma relevante (0,100).

Interpretabilidade no CDC e a causalidade reversa

- Variáveis mais importantes nos 4 modelos: saúde geral autoavaliada, pressão alta, IMC, idade e colesterol.
- A árvore tem 6 folhas. Começa por "tem pressão alta?" e depois usa saúde geral, IMC e colesterol. O grupo de maior risco (59%) tem pressão alta, saúde ruim, IMC 34,5 ou mais e colesterol alto.

Dois resultados da logística parecem estranhos: "checou o colesterol nos últimos 5 anos" tem OR 3,5, e "consumo pesado de álcool" tem OR 0,46. Nenhum dos dois é causa. A pesquisa é transversal (uma foto de um momento), e provavelmente o diabetes veio antes: quem já tem diabetes checa mais o colesterol e foi orientado a parar de beber. Isso se chama **causalidade reversa**.

As limitações e como falar de cada uma

Limitação reconhecida não é fraqueza, é maturidade.

Limitação	Como responder
Pima é pequena e específica	Por isso a replicação no CDC, onde a conclusão se manteve
Hiperparâmetros fixos	Escolha para evitar otimismo; os ensembles teriam que ganhar 25 vezes mais para mudar a conclusão
Limiar 0,5 privilegia a especificidade	Por isso o ponto de triagem com sensibilidade de 80%
MICE com $m = 1$ na validação cruzada	Custo computacional; mediana e MICE deram a mesma AUC; nos odds ratios, $m = 20$
MICE supõe que a falta depende só do observado (MAR)	Não dá para verificar; por isso quatro estratégias, com a mesma conclusão
GBM parou com poucas árvores (OOB)	Afeta a calibração, não a AUC; no CDC bateu no teto de 1.500 árvores e poderia ganhar um pouco, longe de 0,05
Critérios de interpretabilidade são escolha do grupo	Não há métrica consagrada, mas a diferença de tamanho é enorme
CDC autodeclarado, transversal, junta pré-diabetes e diabetes	Por isso o CDC é tratado como replicação, sem leitura causal

Frase para a apresentação

Repetimos o experimento numa base com 253 mil pessoas. As AUCs ficaram praticamente iguais às da Pima. Com tantos dados, a vantagem do gradient boosting se tornou estatisticamente significativa, mas é de apenas 0,007, muito abaixo do limite de 0,05: é real, mas clinicamente irrelevante. A conclusão se manteve.

Os scripts do repositório

Dois "maestros" rodam os scripts em ordem: `run_all.R` (Pima) e `run_cdc.R` (CDC). Os scripts compartilham variáveis (o 01 cria a base, o 02 usa a base e cria os resultados, o 03 usa os resultados), então a ordem importa.

Ordem de execução

1. `R/00_setup.R` e `R/funcoes.R` : configuração e caixa de ferramentas (usados pelas duas análises).
2. `R/01_dados.R` : carrega e explora a base.
3. `R/02_validacao_cruzada.R` : treina e testa os modelos (a parte pesada).
4. `R/03_comparacao.R` : compara os modelos e responde aos objetivos.
5. `R/04_interpretabilidade.R` : mostra o que cada modelo aprendeu.

O CDC repete a mesma numeração em `R/cdc/` , depois de rodar também `R/cdc/00_setup_cdc.R` .

Os maestros

Arquivo	O que faz
<code>run_all.R</code>	Grava o console em <code>resultados_log.txt</code> (com <code>sink()</code>), roda os scripts da Pima em ordem e, no fim, imprime o <code>sessionInfo()</code> (versões do R e dos pacotes, para reprodutibilidade). Com <code>--sem-cv</code> , pula o script 02 e lê os resultados já salvos em CSV
<code>run_cdc.R</code>	O mesmo para o CDC, com log em <code>resultados_cdc_log.txt</code> . Com <code>--amostra=N</code> , roda numa amostra para testar rápido, salvando fora do Git

Configuração e ferramentas

Arquivo	O que faz
<code>R/00_setup.R</code>	Instala e carrega os pacotes (<code>rpart</code> , <code>randomForest</code> , <code>gbm</code> , <code>pROC</code> , <code>mice</code> , <code>ggplot2</code> , <code>partykit</code>). Define semente 2026, 10 partes, 5 repetições, limiar 0,5, régua 0,05 e MICE como estratégia principal. Define rótulos em português, cores, tema dos gráficos e vírgula decimal
<code>R/cdc/00_setup_cdc.R</code>	Parâmetros do CDC (5 partes, 2 repetições), rótulos das 21 variáveis, unidades práticas dos odds ratios (IMC por +5, por exemplo), troca a random forest pelo <code>ranger</code> e cria as funções de AUC-PR e das métricas no limiar da prevalência
<code>R/funcoes.R</code>	A caixa de ferramentas (detalhes abaixo)

A caixa de ferramentas: `R/funcoes.R`

Função	O que faz
<code>zeros_para_na()</code>	Troca os zeros impossíveis por NA
<code>trat_zeros_mantidos()</code> , <code>trat_casos_completos()</code> , <code>trat_mediana()</code> , <code>trat_mice()</code>	As 4 estratégias de faltantes. Recebem treino e teste e devolvem os dois prontos, aprendendo só com o treino

Função	O que faz
<code>MODELOS</code>	Lista com os 4 modelos. Cada um tem <code>ajustar(treino)</code> e <code>prever(modelo, teste)</code> , que devolve a probabilidade
<code>calcular_metricas()</code>	Monta a matriz de confusão e calcula AUC, acurácia, sensibilidade, especificidade, precisão, F1 e Brier
<code>criar_folds()</code>	Cria as divisões estratificadas (sorteia separado dentro de cada classe)
<code>teste_t_corrigido()</code>	O teste de Nadeau e Bengio: devolve diferença, IC 95% e p-valor

Como todos os modelos e todas as estratégias têm o mesmo formato, o script 02 roda qualquer combinação com o mesmo laço. Para acrescentar um quinto modelo, bastaria mais um item em `MODELOS`.

Os scripts de análise

Arquivo	O que faz	Saídas principais
<code>R/01_dados.R</code>	Lê a Pima e confere que tem 768 linhas e 9 colunas (se não tiver, para com erro). Conta os zeros, calcula médias por grupo e o teste de Wilcoxon	<code>01_descritiva.csv</code> , <code>01_zeros_invalidos.csv</code> e 2 figuras
<code>R/02_validacao_cruzada.R</code>	Laço de 4 níveis: estratégia, repetição, parte e modelo. Treina 800 modelos no total, com a mesma semente para os 4 modelos em cada parte. Leva cerca de 2 minutos	<code>02_cv_por_fold.csv</code> (800 linhas, a tabela-mãe) e <code>02_predicoes_oof.csv</code> (a probabilidade de cada paciente quando estava na prova)
<code>R/03_comparacao.R</code>	Resume as métricas; compara cada modelo com a logística (objetivo 2); mede a perda do modelo interpretável (objetivo 3); compara as estratégias (objetivo 4); calcula a triagem com sensibilidade de 80% e a calibração	6 tabelas e 4 figuras
<code>R/04_interpretabilidade.R</code>	Treina os modelos com as 768 pacientes só para inspeção. Calcula os odds ratios com imputação múltipla ($m = 20$) e a análise dos 3 cenários; escreve as regras da árvore; calcula as importâncias (escala 0 a 100) e os critérios de interpretabilidade	5 tabelas, 4 figuras e <code>modelos_finais.rds</code> (fora do Git)

O que muda no CDC

Arquivo	Diferenças
<code>R/cdc/01_dados.R</code>	Baixa a base do UCI na primeira vez e depois usa a cópia local. Usa SMD em vez de p-valor

Arquivo	Diferenças
R/cdc/02_validacao_cruzada.R	5 partes vezes 2, sem estratégias de faltantes. Guarda as curvas ROC resumidas em cerca de 500 pontos. Leva cerca de 50 minutos
R/cdc/03_comparacao.R	Objetivos 2 e 3 e a comparação Pima vs. CDC. Lê as tabelas da Pima, por isso o <code>run_all.R</code> precisa rodar antes
R/cdc/04_interpretabilidade.R	Odds ratios com unidades práticas, sem imputação. Desenha a árvore só se tiver até 12 folhas. Não salva os modelos (a random forest teria centenas de MB)


As figuras e como ler cada uma

São 10 figuras da Pima e 7 do CDC, em 300 dpi. O prefixo do nome diz qual script gerou cada uma. As quatro mais importantes para o pôster são `04_equilibrio`, `03_auc_por_modelo`, `04_odds_ratios` e `cdc/03_pima_vs_cdc`.

Onde usar	Figuras
Pôster (essenciais)	<code>04_equilibrio</code> , <code>03_auc_por_modelo</code> , <code>04_odds_ratios</code> , <code>cdc/03_pima_vs_cdc</code>
Slides de método	<code>01_zeros_invalidos</code> , <code>03_curvas_roc</code>
Slides de resultados	As do pôster, mais <code>03_estrategias_ausentes</code> e <code>04_arvore_decisao</code>
Guardar para perguntas	<code>03_calibracao</code> , <code>04_importancia_variaveis</code> e as do CDC

Pima

`04_equilibrio.png` : a resposta da pergunta de pesquisa. Cada modelo é um ponto. Eixo vertical: AUC, com barras de ± 1 desvio-padrão. Eixo horizontal: tamanho do modelo em escala logarítmica (cada marca vale 10 vezes a anterior). A faixa azul é a zona de perda até 0,05. O ideal é estar no alto e à esquerda: só a logística está dentro da faixa e à esquerda. A árvore é pequena mas fica abaixo; RF e GBM estão na faixa, mas à direita.




Desempenho vs. tamanho do modelo

`03_auc_por_modelo.png` : o resultado principal de desempenho. Cada ponto é a AUC de uma das 50 provas; o boxplot resume e o círculo branco é a média. As nuvens de logística, RF e GBM estão sobrepostas; a da árvore está à esquerda e mais espalhada (menos estável).

AUC-ROC na validação cruzada 10-fold × 5 repetições

Ausentes: Imputação múltipla (MICE) · ponto = 1 fold · círculo = média




AUC por modelo

04_odds_ratios.png : a leitura da logística. Cada ponto é um OR e a barra é o IC 95%. A linha tracejada é o 1 (sem efeito). À direita aumenta o risco, à esquerda diminui. Se a barra cruza a linha tracejada, não é significativo (ponto vazio). O eixo é logarítmico, para que "dobra" e "cai pela metade" fiquem à mesma distância do 1.


Regressão logística: odds ratio por +1 desvio-padrão

IC 95% por imputação múltipla (m = 20) · OR > 1 aumenta a chance · escala log




Odds ratios


01_zeros_invalidos.png : o problema dos dados. Barras com a porcentagem de pacientes com zero em cada variável. Insulina (48,7%) e dobra cutânea (29,6%) se destacam. Serve para motivar o objetivo 4.



01_distribuicoes.png : as variáveis separam os grupos? Um painel por variável, com dois boxplots (azul sem diabetes, laranja com diabetes). No boxplot, a caixa vai do 1º ao 3º quartil, a linha de dentro é a mediana e os pontos soltos são extremos. Quanto mais as caixas estão deslocadas, mais a variável separa; a glicose é a campeã.



03_curvas_roc.png : as curvas ROC. Uma curva por modelo, com a AUC na legenda (predições da 1ª repetição, cada paciente uma vez). Eixo horizontal: alarmes falsos; vertical: sensibilidade. A diagonal é o chute. A curva da árvore tem degraus grandes porque só dá 3 níveis de risco.




Curvas ROC

03_estrategias_ausentes.png : o objetivo 4. AUC média de cada modelo nas 4 estratégias, com barras de ± 1 desvio-padrão. Mediana e MICE dão o mesmo resultado. Casos completos ficam mais altos, mas com barras maiores (menos estáveis). A ordem dos modelos é a mesma em todas.

Efeito do tratamento dos valores ausentes

AUC média $\pm$ 1 DP entre os 50 folds (DP = estabilidade)




Estratégias de ausentes

03_calibracao.png : o risco previsto bate com a realidade? Um painel por modelo. As pacientes são divididas em 10 grupos pelo risco previsto; cada ponto mostra o risco médio previsto contra a proporção real de diabéticas. O ideal é seguir a diagonal. O GBM fica abaixo dela à esquerda e acima à direita: o formato de probabilidades tímidas.

Calibração: o risco previsto bate com o observado?


Predições fora-do-fold (MICE, 5 repetições) agrupadas em decis · diagonal = calibração perfeita



Calibração


04_arvore_decisao.png : a árvore final. As perguntas nos nós e, nas folhas, a classe prevista, o risco e quantas pacientes caíram ali. Comece do topo e desça conforme as respostas.

Árvore de decisão final (CART podada, regra do 1-SE)



Árvore de decisão

04_importancia_variaveis.png : os modelos concordam? Quatro painéis com a importância em escala de 0 a 100 (100 = a mais importante daquele modelo). Glicose e IMC estão no topo em todos. Compare a ordem, não o tamanho das barras entre modelos.




Importância das variáveis


CDC

Todas as figuras do CDC já estão na versão final, com vírgula decimal.


cdc/03_pima_vs_cdc.png : a conclusão se repete. A AUC média de cada modelo nas duas bases, lado a lado. Os pontos estão quase na mesma posição, e a árvore fica atrás nas duas. As barras do CDC são muito mais curtas: mais dados, menos incerteza.




cdc/01_prevalencia_por_fator.png : para cada fator, dois pontos ligados: a porcentagem de diabéticos entre quem não tem o fator (azul) e entre quem tem (laranja). Quanto mais longa a linha, mais forte a associação. A linha tracejada é a prevalência geral (13,9%).




cdc/03_auc_por_modelo.png : dois painéis, AUC-ROC e AUC-PR. Cada ponto é uma das 10 provas. Os pontos quase não se espalham. Na AUC-PR, a referência do chute é 0,14.



cdc/03_curvas_roc.png : mesma leitura da Pima; as curvas são mais lisas porque têm 253 mil pessoas.




cdc/04_odds_ratios.png : mesma leitura da Pima, mas com unidades práticas ("sim vs. não", "+5 kg/m²") e cores para aumenta (laranja) ou reduz (azul) o risco. "Checou colesterol" e "consumo pesado de álcool" são causalidade reversa, não efeitos reais.



Odds ratios no CDC

cdc/04_arvore_decisao.png : a árvore com 6 folhas, começando por pressão alta.

Árvore de decisão final no CDC (CART podada, regra do 1-SE)




Árvore no CDC

cdc/04_importancia_variaveis.png : mesma leitura da Pima, com 21 variáveis. No topo: saúde geral, pressão alta, IMC, idade e colesterol.

Importância relativa das variáveis em cada modelo (CDC)

100 = variável mais importante do modelo - logística: [z]; árvore: redução de impureza; RF: permutação; GBM: influência relativa



Importância no CDC

Perguntas prováveis da banca

Respostas curtas para revisar antes da apresentação. O simulador de banca traz as mesmas perguntas para treinar.

Tema	Pergunta	Resposta curta
Projeto	Qual é a pergunta de pesquisa?	Qual modelo tem o melhor equilíbrio entre desempenho e interpretabilidade na predição de diabetes
Projeto	Qual a resposta?	A regressão logística: perda de 0,002 contra a régua de 0,05, lida com 9 números
Projeto	Por que isso importa?	Na saúde, o médico precisa entender o modelo. Se a transparência não custa desempenho, não há motivo para caixa-preta (Rudin, 2019)
Dados	Por que a Pima?	Base clássica, comparável com a literatura, e com um problema real de faltantes
Dados	O que são os zeros?	Exames não registrados, disfarçados de zero; são fisiologicamente impossíveis
Dados	Por que o CDC?	Testar se a conclusão se mantém numa base 330 vezes maior. É replicação, não validação externa
Método	Por que AUC e não acurácia?	A AUC não depende do limiar e não é enganada pelo desbalanceamento
Método	O que é a AUC?	A chance de o modelo dar risco maior a um doente do que a um saudável
Método	Por que validação cruzada 10 vezes 5?	50 avaliações em dados não vistos, com média e variação, sem depender da sorte de uma divisão
Método	O que é vazamento e como evitaram?	Usar informação do teste no treino. Todo preenchimento foi aprendido só com o treino de cada rodada
Método	Por que o teste t corrigido?	As rodadas compartilham pacientes; o teste comum exageraria a certeza
Método	De onde vem o 0,05?	Critério do grupo, definido antes. A diferença real (0,002) é 25 vezes menor
Resultados	Não significativo quer dizer igual?	Não, mas o IC inteiro fica abaixo de 0,05: mesmo no melhor cenário para o GBM, a vantagem não seria relevante
Resultados	No CDC o GBM ganhou com p abaixo de 0,001. E aí?	A diferença é real, mas pequena (+0,007). Significativo não é o mesmo que importante
Resultados	Por que não a árvore, que é mais simples?	Perde 0,107 de AUC, acima da régua, e só dá 3 níveis de risco
Resultados	OR de 3,28 quer dizer que o risco triplica?	A chance fica 3,3 vezes maior; a probabilidade sobe menos (de 35% para 64% no exemplo)

Tema	Pergunta	Resposta curta
Resultados	E o SHAP para explicar o GBM?	Explicações feitas depois são aproximações. Se o modelo transparente acerta igual, é preferível
Resultados	O GBM tem a melhor AUC e a pior calibração. Como?	A AUC mede a ordenação; a calibração mede os números. Ele ordena bem, mas as probabilidades estão comprimidas
Resultados	Casos completos deram a maior AUC. Por quê?	É outra amostra (392 pacientes), menor e menos estável; as notas não são comparáveis
Resultados	Por que a resposta entra no MICE dos ORs e não na validação cruzada?	Na validação cruzada seria dar o gabarito. Nos ORs, sem ela, os coeficientes ficam puxados para 1 (Moons, 2006)
Limitações	O MICE supõe algo sobre por que os dados faltam?	Sim, que a falta depende do que foi observado (MAR). Não dá para verificar; por isso quatro estratégias, com a mesma conclusão
Limitações	Por que não otimizaram os hiperparâmetros?	Para evitar resultado otimista. A vantagem teria que crescer de 0,002 para mais de 0,05