

**Predição de diabetes por aprendizado de máquina supervisionado: uma
comparação de modelos com ênfase em desempenho preditivo e
interpretabilidade**

*Lucas Bacil Karam; Israel Marcos Seixas Zibordi; Victor Henrique de Lima Melo;
Henrique Norio Tanaka Aida Oliveira*

1 Introdução

O diabetes tipo 2 está entre as doenças crônicas que mais crescem no mundo e afeta centenas de milhões de pessoas, boa parte delas sem diagnóstico. Identificar previamente quem está em risco faz uma grande diferença no cuidado, porque permite ação antes das complicações graves, como as renais, cardíacas e de visão. O problema é que tirar esse diagnóstico existe a dependência de vários fatores clínicos ao mesmo tempo, como glicose, índice de massa corporal, pressão, idade e histórico, e cada um deles, isoladamente, diz pouco. Nessa etapa o aprendizado de máquina supervisionado ajuda, já que, com essa estratégia a máquina consegue aprender padrões a com todo o histórico de pacientes, apoiando a decisão do profissional de saúde no diagnóstico.

Decimos usar o Pima Indians Diabetes Dataset, que é um conjunto de dados clínicos bastante conhecido na área como caso de estudo. O dataset reúne variáveis importantes como número de gestações, glicose, pressão arterial, índice de massa corporal e idade. Nossa proposta é desenvolver e comparar, na linguagem R, quatro modelos de classificação de complexidade crescentes: regressão logística, árvore de decisão, random forest e gradient boosting. A grande pergunta da pesquisa é: qual modelo de aprendizado de máquina supervisionado apresentaria o melhor equilíbrio entre desempenho preditivo e interpretação clínica na classificação da presença de diabetes a partir de variáveis clínicas.

2 Justificativa

A escolha do tema saiu de um dilema: quando esses modelos saem do papel e vão para a prática clínica. Os modelos mais precisos (como os métodos ensemble) costumam funcionar como caixas-pretas, o que bota limites e apresenta problemas em processos como a validação, além de reduzir a confiança do profissional de saúde no resultado. Enquanto isso, os modelos mais simples (como a regressão logística) são fáceis de interpretar, mas podem prever com menos precisão. Rudin (2019) defende que "em decisões de alto risco como as da área da saúde, modelos interpretáveis deveriam ser preferidos em vez de explicar modelos opacos depois de prontos", o que demonstra a importância das métricas relacionadas a esse equilíbrio, e não apenas a acurácia.

O interesse pelo tema veio da quantidade de estudos que usam e aplicam aprendizado de máquina ao diagnóstico do diabetes (assim como utilizam para várias outras doenças também). Além disso, após acompanhar o caso de um colega próximo que recebeu o diagnóstico de diabetes tipo 2 tardiamente e apresentou problemas renais, ficou escancarada a necessidade de testar e utilizar aprendizado de máquina para diagnóstico preciso. A experiência motivou a investigação de métodos que possam auxiliar na identificação de pessoas em risco. Os levantamentos de Kavakiotis et al. (2017) e Zou et al. (2018) mostram que: "técnicas de classificação vêm sendo usadas de forma consistente nessa área", enquanto nota-se que pesquisas mais novas continuam realizando a comparação modelos sobre o mesmo conjunto de dados Pima (Chang et al., 2023) visando buscar formas de transformar as previsões em algo mais transparente, interpretável e certo para o uso clínico (Hasan et al., 2025). O estudo de Smith et al. (1988), que deu origem ao próprio dataset, situa historicamente o dilema e serve propósito de ser uma referência para os trabalhos posteriores.

Além da comparação entre modelos, o dataset também levanta um ponto importante em relação ao tratamento de dados: vários valores registrados como zero, (como glicose ou pressão iguais a zero), são dados ausentes, e não medidas reais, o que demanda que seja realizada uma etapa cuidadosa e detalhada de limpeza antes do próximo passo (modelagem). Avaliar como esse tratamento influencia os

resultados também faz parte da justificativa, porque decisões de pré-processamento podem alterar tanto o desempenho quanto a estabilidade dos modelos.

3 Objetivos

Objetivo central: Comparar algoritmos de machine learning avaliando qual deles entrega o melhor desempenho e interpretabilidade clínica, todos de classificação supervisionada visando prever diabetes tipo 2.

- implementar quatro modelos de classificação (regressão logística, árvore de decisão, random forest e gradient boosting) sobre o Pima Indians Diabetes Dataset;
- comparar o desempenho dos métodos que utilizam modelos pequenos trabalhando juntos (ensemble) com o modelo da regressão logística, tendo como métrica principal a AUC-ROC;
- verificar se a escolha do modelo mais interpretável, ao invés do de melhor desempenho, implica perda clinicamente relevante. Se a diferença de AUC entre o melhor modelo e o mais interpretável for maior que 0,05, considera-se perda relevante, caso contrário não tem perda significativa no desempenho;
- investigar como tratar valores ausentes (glicose zero, pressão zero, entre outros) e qual o impacto no desempenho e na estabilidade ao corrigir esse tipo de valor.

4 Orientador e área de afinidade

O professor escolhido para ser orientador do projeto é o Prof. Julio Ardito, que atua com aprendizado de máquina (área próxima do escopo do projeto).

Referências

CHANG, V.; BAILEY, J.; XU, Q. A.; SUN, Z. Pima Indians diabetes mellitus classification based on machine learning (ML) algorithms. **Neural Computing and Applications**, v. 35, n. 22, p. 16157-16173, 2023.

HASAN, R.; DATTANA, V.; MAHMOOD, S.; HUSSAIN, S. Towards transparent diabetes prediction: combining AutoML and explainable AI for improved clinical insights. **Information**, v. 16, n. 1, art. 7, 2025.

KAVAKIOTIS, I. et al. Machine learning and data mining methods in diabetes research. **Computational and Structural Biotechnology Journal**, v. 15, p. 104-116, 2017.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. **Nature Machine Intelligence**, v. 1, n. 5, p. 206-215, 2019.

SMITH, J. W. et al. Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. In: **Proceedings of the Annual Symposium on Computer Application in Medical Care**. [S. l.: s. n.], 1988. p. 261-265.

ZOU, Q. et al. Predicting diabetes mellitus with machine learning techniques. **Frontiers in Genetics**, v. 9, art. 515, 2018.